

La distancia invisible entre lo que creemos y lo que pasa: Entendiendo la divergencia KL

Leonardo Irvin Munguía de la Cruz

Imagine que es meteorólogo en Toluca. Durante años ha observado que, en primavera, el 70 % de los días son soleados, el 20 % nublados y solo el 10 % lluviosos. Con base en esa experiencia histórica, prepara su guardarropa, organiza traslados y aconseja a la comunidad. Sin embargo, un año cualquiera el patrón atmosférico cambia de golpe: llueve la mitad de los días y el sol apenas asoma una vez por semana. La sorpresa constante que usted experimenta cada mañana al mirar por la ventana, y el costo material de haber salido a la calle sin paraguas, representa una manifestación tangible de un concepto central en la teoría de la información: la **divergencia de Kullback–Leibler** o simplemente **divergencia KL**.

Propuesta en 1951 por los matemáticos Solomon Kullback y Richard Leibler, esta herramienta cuantifica cuánta información útil se pierde cuando intentamos representar la realidad concreta mediante un modelo teórico imperfecto. En este marco, solemos llamar P a la distribución real de los hechos (el clima que efectivamente ocurre) y Q a nuestra aproximación o creencia previa (el pronóstico anticipado). La divergencia KL, expresada formalmente como $D_{\text{KL}}(P \parallel Q)$, mide la cantidad de “sorpresa extra” o ineficiencia que acumulamos al describir los fenómenos reales usando únicamente el mapa simplificado que teníamos en mente. Si la hipótesis coincide con la realidad de forma exacta, la divergencia resulta ser estrictamente cero; a medida que la suposición se desvía de los hechos, el valor numérico se incrementa sin límite superior.

Para comprender por qué esta discrepancia suele medirse en unidades de información como los *bits*, basta con mirar el diseño original del código Morse en las telecomunicaciones tempranas. Samuel Morse asignó los pulsos más breves a los caracteres más frecuentes del idioma inglés; por ejemplo, la letra E quedó representada por un simple punto, mientras que letras infrecuentes como la Q recibieron combinaciones de mayor longitud. Dicha optimización permitía transmitir telegramas en el menor tiempo posible. Si tomáramos ese mismo código optimizado para el inglés y lo utilizáramos sin modificaciones para transmitir textos en un idioma donde abundan consonantes raras, el sistema colapsaría en lentitud, gastando una infinidad de pulsos redundantes. La divergencia KL calcula con exactitud matemática ese desperdicio en la longitud del mensaje: los bits adicionales que pagamos por haber codificado la realidad asumiendo frecuencias equivocadas.

A diferencia de la noción intuitiva de distancia física en un mapa, la divergencia KL posee particularidades matemáticas muy marcadas. En primer lugar, siempre arroja valores positivos o nulos, lo que garantiza que nunca se obtendrá mayor eficiencia empleando una conjetura errónea que conociendo la distribución verdadera. En segundo lugar, se trata de una medida **asimétrica**, lo que impide clasificarla como una distancia métrica formal. Esto

significa que evaluar el costo de aproximar P mediante Q arroja un resultado numérico muy distinto al de aproximar Q mediante P , es decir, $D_{\text{KL}}(P \parallel Q) \neq D_{\text{KL}}(Q \parallel P)$. La asimetría acarrea consecuencias severas, si la realidad produce un evento al que nuestro modelo le asignaba probabilidad cero, la divergencia se dispara de inmediato al infinito, penalizando de forma implacable el hecho de haber ignorado una posibilidad real. En cambio, si el modelo contempla escenarios extravagantes que en la práctica nunca suceden, el cálculo registra una ineficiencia costosa pero finita.

Lejos de quedar confinada a los manuales de estadística clásica o al descifrado criptográfico de mediados del siglo XX, la divergencia KL constituye hoy una de las piezas angulares de la inteligencia artificial contemporánea. En el entrenamiento de modelos generativos complejos, como los autocodificadores variacionales que sintetizan imágenes o audio, esta métrica actúa como un regularizador matemático indispensable que obliga a las representaciones internas de la red neuronal a mantenerse ordenadas bajo una distribución probabilística controlada. De igual modo, en el ajuste fino de modelos de lenguaje natural, previene que una red olvide sus capacidades lingüísticas generales mientras aprende tareas nuevas y especializadas. Su alcance trasciende incluso las ciencias computacionales: en la física estadística ayuda a calcular la disipación irreversible de energía en sistemas termodinámicos, mientras que en la neurobiología teórica fundamenta hipótesis sobre cómo el cerebro humano actualiza continuamente sus esquemas sensoriales para reducir al mínimo el desfase entre sus expectativas y el entorno.

Uso de GenAI

- Herramienta: Gemini 3.5 - Uso: Ideas de ejemplos

Referencias

1. Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
2. Cover, T. M., & Thomas, J. A. (2006). *Elements of Information Theory* (2.^a ed.). Wiley-Interscience.
3. Kullback, S., & Leibler, R. A. (1951). On information and sufficiency. *The Annals of Mathematical Statistics*, 22(1), 79–86.
4. MacKay, D. J. C. (2003). *Information Theory, Inference, and Learning Algorithms*. Cambridge University Press.